

# Pytorch中常见的损失函数的原理

本文介绍在pytorch中常用的几种损失函数的原理及代码实现，以方便后续自查，但本文未对其中的数学原理进行详细介绍，后续有需要可再进行补充。

## 1. MSE Loss

均方损失函数，适用于回归任务。一般损失函数都是计算一个 batch 数据总的损失，而不是计算单个样本的损失。

计算公式：

$$\ell(x, y) = L = \{l_1, \dots, l_N\}^\top, \quad l_n = (x_n - y_n)^2$$

其中x是Input, y表示target

参数说明：

```
CLASS torch.nn.MSELoss(size_average=None, reduce=None, reduction='mean')
```

reduce与size\_average:

reduce = False, 损失函数返回的是向量形式的 loss, 这种情况下参数 size\_average 失效

reduce = True, 损失函数返回的是标量形式的 loss, 这种情况下:

- 1) 当 size\_average = True 时, 返回 loss.mean(), 即所有向量元素求和后再除以向量长度
- 2) 当 size\_average = False 时, 返回 loss.sum(), 即所有向量元素只求和

reduction: 默认是mean, 还可以是sum

代码示例:

```
import torch
import torch.nn as nn
import torch.nn.functional as F
```

```
# 1. 调用MSELoss
mse_loss_fn = torch.nn.MSELoss() # 默认输出标量并求均值
input = torch.randn(2, 4, requires_grad=True)
target = torch.randn(2, 4)
output = mse_loss_fn(input, target)
print(output.item())
```

```
2.2671520709991455
```

## 2. BCE Loss

只适用与二分类任务，且神经网络的输出是一个概率分布，一般输出层的激活函数是 Sigmoid 函数（返回一个概率数值，那么可以理解为一类的概率），因为只有两类，所以输出没必要归一化，直接就是一个概率分布。

计算公式：

一个batch数据的损失为：

$$L_{batch} = -w \cdot [y \ln \hat{y} + (1 - y) \ln(1 - \hat{y})]$$

一个样本的损失为：

$$L_{one} = -[y \ln \hat{y} + (1 - y) \ln(1 - \hat{y})]$$

### 参数说明：

```
CLASS torch.nn.BCELoss(weight=None, size_average=None, reduce=None,
reduction='mean')
```

weight: weight 必须和 target 的 shape 一致

reduce与size\_average:

reduce = False, 损失函数返回的是向量形式的 loss, 这种情况下参数 size\_average 失效

reduce = True, 损失函数返回的是标量形式的 loss, 这种情况下:

- 1) 当 size\_average = True 时, 返回 loss.mean(), 即所有向量元素求和后再除以向量长度
- 2) 当 size\_average = False 时, 返回 loss.sum(), 即所有向量元素只求和

reduction: 默认是mean, 还可以是sum

### 输入值与目标值说明:

input: 可以是任意维度, 保证是log的一个概率

target: 与input一致, 默认情况是线性的概率

outputz: 一般是一个张量

### 代码示例:

```
# logits shape: [BS,NC] Logits可以理解为输出的一个概率分布
# 定义一些通用的
batch_size = 2
num_class = 4

logits = torch.randn(batch_size,num_class) # 未归一化分数, 作为损失函数的输入

target_indices = torch.randint(num_class,size = (batch_size,)) # 形成的是
[0,num_class-1]范围的索引的目标分布
target_logits = torch.randn(batch_size,num_class) # 形成的是目标概率分布
```

```
## 2. 调用Binary Cross Entropy loss (BCE Loss)
bce_loss_fn = torch.nn.BCELoss()
logits = torch.randn(batch_size) # 这是logits
prob_1 = torch.sigmoid(logits) # 这是概率
# 如果神经网络输出的是logits, 那么就用BCEwithlogitsloss这个方法
target = torch.randint(2,size=(batch_size,))
bce_loss = bce_loss_fn(prob_1,target.float())
print(f"binary cross entropy loss: {bce_loss}")

### 用NLLLoss (本文后面会讲到) 代替BCE LOSS做二分类
prob_0 = 1 - prob_1.unsqueeze(-1) # 但是要进行扩充
```

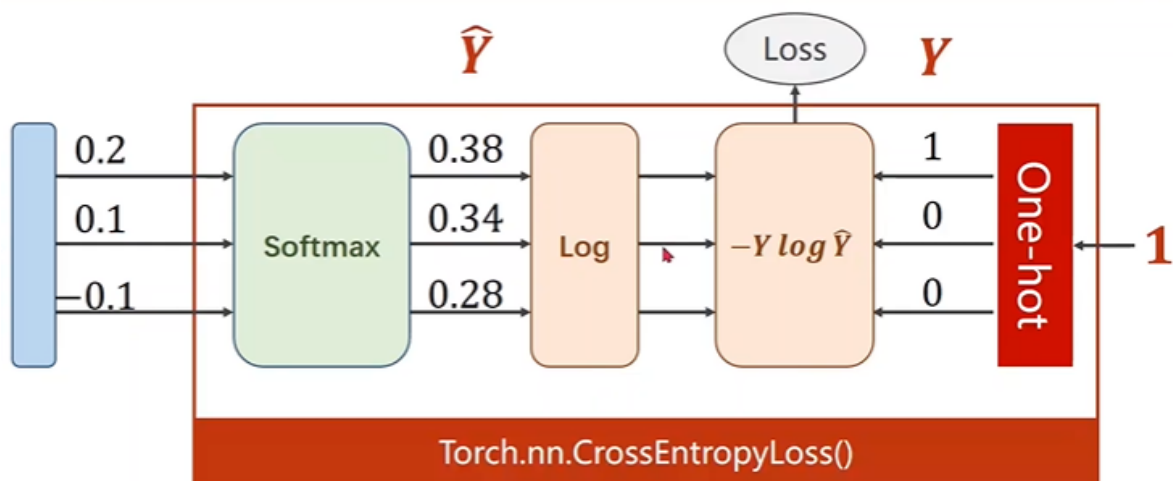
```
prob = torch.cat([prob_0, prob_1.unsqueeze(-1)], dim=-1) # [BS, 2]
nll_loss_binary = nll_fn(torch.log(prob), target)
print(f"negative likelihood loss binary is: {nll_loss_binary}")
```

```
binary cross entropy loss: 0.4194680452346802
negative likelihood loss binary is: 0.4194680452346802
```

### 3. CrossEntropyLoss

用于分类任务中，常用于多分类

当使用 CrossEntropyLoss 损失函数的时候，神经网络的输出就不用再接 softmax 层了，因为这个损失函数内部会做这个归一化，同时它还会根据对应的输出标签 y 生成 one-hot 向量。如下图所示：



交叉熵计算公式：

$$H(p, q) = - \sum_{i=1}^N p(x_i) \ln q(x_i)$$

其中p表示真实分布，q表示预测分布

参数说明：

```
CLASS torch.nn.CrossEntropyLoss(weight=None, size_average=None, ignore_index=
100, reduce=None, reduction='mean', label_smoothing=0.0
```

weight：分类类别明显不均衡的话，会设置weight来使得更均衡

ignore\_index：类似padding的操作，一般设置ignore\_index = 0，传入之后，如果目标为 ignore\_index，就不会考虑那个位置

reduction：默认是mean，还可以是sum

label\_smoothing：把目标的概率值降低点，相当于平滑化的操作

输入值与目标值说明：

input：输入（在模型中，也就是模型的输出值，放入损失中作为输入）是**未归一化**的一个分数。 $(N, C)$  or  $(C)$ , where  $C = \text{number of classes}$ , or  $(N, C, d_1, d_2, \dots, d_K)$  ( $N, C, d_1, d_2, \dots, d_K$ ) with  $K \geq 1$  in the case of K-dimensional loss. (这些d可理解为时空维度，如d1为视频高度；d2为视频宽度；d3为视频通道数目；d4为视频时间维度)

target: 传入的是类别标签, 如果input是(C)的话, 那么target形状就是(); 如果input是(N,C)的话, 那么target形状就是(N); 如果input是(N, C, d\_1, d\_2, ..., d\_K)的话, 那么target形状就是(N, d\_1, d\_2, ..., d\_K)。总之就是少了C这一维, 每一个值范围是[0,C)

output: If reduction is none, 那么就与target一致, 反之就是标量

**代码示例:**

```
## 3. 调用Cross Entropy Loss (CE Loss)
### method1 for CE Loss
ce_loss_fn = torch.nn.CrossEntropyLoss()
ce_loss1 = ce_loss_fn(logits,target_indices)
print(f"cross entropy loss is {ce_loss1}")

### method2 for CE Loss
ce_loss2 = ce_loss_fn(logits,torch.softmax(target_logits,dim=-1))
print(f"cross entropy loss is {ce_loss2}")
```

```
cross entropy loss1 is 1.4498498439788818
cross entropy loss2 is 1.7070740461349487
```

## 4. NLLLoss (负对数似然Loss)

交叉熵就是负对数似然

```
CLASS torch.nn.NLLLoss(weight=None, size_average=None, ignore_index=- 100,
reduce=None, reduction='mean')
```

**参数说明:**

weight: 分类类别明显不均衡的话, 会设置weight来使得更均衡

ignore\_index: 类似padding的操作, 一般设置ignore\_index = 0, 传入之后, 如果目标为ignore\_index, 就不会考虑那个位置

reduction: 默认是mean, 还可以是sum

label\_smoothing: 把目标的概率值降低点, 相当于平滑化的操作

**输入值与目标值说明:**

input: 输入 (在模型中, 也就是模型的输出值, 放入损失中作为输入) 必须是每个类别的对数概率, 并且是做了对数化的。(N,C) or (C), where C = number of classes, or (N, C, d\_1, d\_2, ..., d\_K) with K≥1 in the case of K-dimensional loss.

target: 是一个索引, 范围是[0,C-1], 其中C为类别的数目。形状是 (N) or 一个标量 or (N, C, d\_1, d\_2, ..., d\_K) with K≥1 in the case of K-dimensional loss.

output: If reduction is none, shape (N) or (N, C, d\_1, d\_2, ..., d\_K) with K≥1 in the case of K-dimensional loss.否则就是标量。

**代码示例:**

```
## 4. 调用Negative Log Likelihood loss (NLL Loss)
nll_fn = torch.nn.NLLLoss()
nll_loss = nll_fn(torch.log(torch.softmax(logits,dim=-1)),target_indices)
print(f"negative log likelihood loss is {nll_loss}")
## 重要结论: cross entropy value = NLL value
```

```
negative log likelihood loss is 1.4498497247695923
```

## 5. KL散度 Loss

KL散度计算公式:

$$D_{KL}(p||q) = H(p,q) - H(p)$$

参数说明:

```
CLASS torch.nn.KLDivLoss(size_average=None, reduce=None, reduction='mean',
log_target=False)
```

reduce与size\_average:

reduce = False, 损失函数返回的是向量形式的 loss, 这种情况下参数 size\_average 失效

reduce = True, 损失函数返回的是标量形式的 loss, 这种情况下:

- 1) 当 size\_average = True 时, 返回 loss.mean(), 即所有向量元素求和后再除以向量长度
- 2) 当 size\_average = False 时, 返回 loss.sum(), 即所有向量元素只求和

reduction: 默认是mean, 还可以是sum

log\_target: 表示是否对目标值求log

输入值与目标值说明:

input: 可以是任意维度, 保证是log的一个概率

target: 与input一致, 默认情况是线性的概率

output: 默认是一个标量, 如果redution为"none", 那么与输入具有相同形状

代码示例:

```
## 4. 调用Kullback-Leibler divergence loss (KL Loss)
kid_loss_fn = torch.nn.KLDivLoss()
kid_loss =
kid_loss_fn(torch.softmax(logits,dim=-1),torch.softmax(target_logits,dim=-1))
print(f"kullback-Leibler divergence loss is {kid_loss}")
```

```
kullback-Leibler divergence loss is -0.3704858124256134
```

验证CE = IE + KLD(交叉熵 = 信息熵 + KL散度)

```
# 验证的时候就按样本了
ce_loss_fn_sample = torch.nn.CrossEntropyLoss(reduction="none")
ce_loss_sample = ce_loss_fn_sample(logits,torch.softmax(target_logits,dim=-1))
print(f"cross entropy loss sample is {ce_loss_sample}")

kid_loss_fn_sample = torch.nn.KLDivLoss(reduction="none")
kid_loss_sample =
kid_loss_fn_sample(torch.log(torch.softmax(logits,dim=-1)),torch.softmax(target_
logits,dim=-1)).sum(dim=-1)
print(f"kullback-Leibler divergence loss sample is {kid_loss_sample}")

target_information_entropy =
torch.distributions.Categorical(torch.softmax(target_logits,dim=-1)).entropy()
print(f"information entropy sample is {target_information_entropy}") # IE为常数,
如果目标分布是delta分布, IE=0

print(torch.allclose(ce_loss_sample,kid_loss_sample+target_information_entropy))
```

```
cross entropy loss sample is tensor([1.4442, 1.9700])
kullback-Leibler divergence loss sample is tensor([0.2811, 0.7337])
information entropy sample is tensor([1.1631, 1.2363])
True
```

## 6. 余弦相似度 Loss

根据余弦相似度来判断输入的两个数是相似还是不相似的（在对比学习、自监督学习、文本相似度、图片相似度、图片检索中比较常用）

```
CLASS torch.nn.CosineEmbeddingLoss(margin=0.0, size_average=None, reduce=None,
reduction='mean')
```

### 参数说明:

margin: 是一个-1 到 1, 0 到 0.5 的数, 默认为0

reduce与size\_average:

reduce = False, 损失函数返回的是向量形式的 loss, 这种情况下参数 size\_average 失效

reduce = True, 损失函数返回的是标量形式的 loss, 这种情况下:

- 1) 当 size\_average = True 时, 返回 loss.mean(), 即所有向量元素求和后再除以向量长度
- 2) 当 size\_average = False 时, 返回 loss.sum(), 即所有向量元素只求和

reduction: 默认是mean, 还可以是sum

### 输入值与目标值说明:

input1: (N,D)或(D), 其中N是batch\_size, D是embedding dimension

input2: 与input1一致

target: (N) 或 () -1或1

output: 如果redution为"none", 那么就是(N), 否则就是标量

### 代码示例:

```
## 6.调用Cosine Similarity loss
cosine_loss_fn = torch.nn.CosineEmbeddingLoss()
v1 = torch.randn(batch_size,512)
v2 = torch.randn(batch_size,512)
target = torch.randint(2,size = (batch_size,))*2 - 1 # torch.randint(2是 0,1 *2
是0,2 -1 就是 -1,1
cosine_loss = cosine_loss_fn(v1,v2,target)
print(f"Cosine Similarity loss is: {cosine_loss}")
```

Cosine Similarity loss is: 0.942288875579834

参考：

- Pytorch官方文档: <https://pytorch.org/>
- B站up主deep\_thoughts讲解: [Pytorch常见损失函数原理及实现](#)
- 博客: [Pytorch之损失函数](#)
- KL散度和交叉熵基础: [KL散度和交叉熵](#)