五种归一化原理及实现

Batch Normalization

per channel, across, mini-batch

总结一句话BN就是:做的是通道级别的归一化(每个通道单独算),贯穿到每个mini batch,在计算统计量的时候要考虑到整个batch

CLASS torch.nn.BatchNorm1d(num_features, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True, device=None, dtype=None)

num_features: 输入的通道数

eps: 用于数值的稳定性的 (如分母为0)

momentum: 动量,与track_running_stat联合起来用,统计量是通过滑动平均来计算,是累计的过程。作用是当走到局部最小时,此时不只是看梯度,还要根据前一步的动量

affine: 默认True, 做完归一化之后, 还可以加一个映射, 映射到一个新的分布, 比如re-scale、recenter

```
import torch
import torch.nn as nn
```

```
# UNLP举例 batch_size * 序列长度 * 特征维度
batch_size = 2
time_steps = 3
embedding_dim = 4
num_groups= 2
input_x = torch.randn(batch_size,time_steps,embedding_dim) # N * L * C
```

```
# 1. 实现batch_norm并验证API
# per channel, across, mini-batch
# NLP: [N,L,C] --> [C] 保持通道维度(per channel)
# CV: [N,C,H,W] --> [C]
## 调用batch_norm API
batch_norm_op = torch.nn.BatchNorm1d(embedding_dim,affine=False)
# 因为要求输入是 N * C * L, 所以先变换, 再换回来
bn_y = batch_norm_op(input_x.transpose(-1,-2)).transpose(-1,-2)
# 手写batch_norm
# 在batch_size维和序列长度维求均值(因为BN是按通道的,所以其他维求均值)
bn_mean = input_x.mean(dim=(0,1),keepdim=True) # 求完之后是C大小,然后用keepdim变回来
# 注意加上unbiased=False, 因为要求是有偏估计
bn_std = input_x.std(dim=(0,1),unbiased=False,keepdim=True) # 求完之后是C大小,然后
用keepdim变回来
verify_bn_y = (input_x - bn_mean)/(bn_std + 1e-5) # 1e-5  \# eps
# 验证是否相等
print(bn_y)
print(verify_bn_y)
```

Layer Normalization

```
per sample, per layer
```

总结:对单一样本计算,而且是对每一层进行计算,一般用于NLP任务

CLASS torch.nn.LayerNorm(normalized_shape, eps=1e-05, elementwise_affine=True, device=None, dtype=None)

normalized_shape: 需要进行归一化的shape (一般是特征维度)

eps: 用于数值的稳定性的 (如分母为0)

elementwise_affine: 默认True, 做完归一化之后, 还可以加一个映射, 映射到一个新的分布, 比如rescale、re-center

```
# 2.实现layer_norm并验证API(per sample per layer)
# 输入的是特征维度
# NLP: [N,L,C] --> [N,L] 保持样本和layer维度
# CV: [N,C,H,W] --> [N,H,W]
## API
layer_norm_op = torch.nn.LayerNorm(embedding_dim,elementwise_affine=False)
ln_y = layer_norm_op(input_x)

## 手写
# 因为是per sample per layer,所以对最后一个维度进行mean
ln_mean = input_x.mean(dim=-1,keepdim=True)
ln_std = input_x.std(dim=-1,unbiased=False,keepdim=True)
verify_ln_y = (input_x - ln_mean)/(ln_std + le-5) # le-5 是eps
# 验证是否相等
print(ln_y)
print(verify_ln_y)
```

Instance Normalization

总结: 对单一样本计算, 还对每个通道进行计算, 一般用于风格迁移

CLASS torch.nn.InstanceNorm1d(num_features, eps=1e-05, momentum=0.1, affine=False, track_running_stats=False, device=None, dtype=None)

num_features: 特征维度 (通道维度)

eps: 用于数值的稳定性的 (如分母为0)

momentum:动量,与track_running_stat联合起来用,统计量是通过滑动平均来计算,是累计的过

程。作用是当走到局部最小时,此时不只是看梯度,还要根据前一步的动量

affine:实例归一化中默认为False,与BN、LN不一样

```
# 3.实现instance_norm并验证API(per sample per channel)
# 输入的是特征维度
# NLP: [N,L,C] --> [N,C] 保持样本和channel维度
# CV: [N,C,H,W] --> [N,C]
## InstanceNorm1d API
instance_norm_op = torch.nn.InstanceNorm1d(embedding_dim)
in_y = instance_norm_op(input_x.transpose(-1,-2)).transpose(-1,-2) # 这个就看官方文
档
## 手写 InstanceNor
# 因为是per sample per channel, 所以返回的是 N * C, 所以对第二个维度进行mean
in_mean = input_x.mean(dim=1,keepdim=True)
in_std = input_x.std(dim=1,unbiased=False,keepdim=True)
verify_in_y = (input_x - in_mean)/(in_std + 1e-5) # 1e-5 是eps
# 验证是否相等
print(in_y)
print(verify_in_y)
```

```
[[ 0.6581, -0.5001, -0.8212, -0.6020],
[ 0.7549, 1.3956, 1.4076, -0.8073],
[-1.4131, -0.8955, -0.5865, 1.4092]]])
```

Group Normalization

per sample, per group

与Layer Normalization很像,不过得先将Layer划分为Group

CLASS torch.nn.GroupNorm(num_groups, num_channels, eps=1e-05, affine=True, device=None, dtype=None)

num_groups: group数目

eps: 用于数值的稳定性的 (如分母为0)

affine: 默认True, 做完归一化之后, 还可以加一个映射, 映射到一个新的分布, 比如re-scale、recenter

```
# 4.实现group_norm并验证API(per sample per group)
# 输入的是特征维度
# NLP: [N,G,L,C//G] --> [N,G] 保持样本和group维度
# CV: [N,G,C//G,H,W] --> [N,G]
group_norm_op = torch.nn.GroupNorm(num_groups,embedding_dim,affine=False)
gn_y = group_norm_op(input_x.transpose(-1,-2)).transpose(-1,-2) # 这个就看官方文档
# 手写group_norm
# 先把embedding_dim分割成两组
# 参数意思:对哪个数据分割,每一块大小,在这个数据上的哪一维进行分割
group_inputxs = torch.split(input_x,split_size_or_sections=embedding_dim //
num_groups,dim=-1)
results = []
for g_input_x in group_inputxs:
   # 因为是per sample per group 所以在除了sample的那一维(即batch_size)进行mean
   gn_mean = g_input_x.mean(dim=(1,2),keepdim=True)
   # print(gn_mean.shape) # torch.Size([2, 1, 1])
   gn_std = g_input_x.std(dim=(1, 2), unbiased=False,keepdim=True)
   gn_result = (g_input_x - gn_mean)/(gn_std + 1e-5)
   # print(gn_result.shape) # torch.Size([2, 3, 2])
    results.append(gn_result) # 列表, 里面有两个元素, 每个元素是torch.Size([2, 3, 2])
verify_gn_y = torch.cat(results,dim=-1) # 在embedding_dim这个维度上将results列表中的
两个tensor元素进行拼接,形成 N * L * C
# print(verify_gn_y.shape) # torch.Size([2, 3, 4])
# 验证是否相等
print(gn_y)
print(verify_gn_y)
```

Weight Normalization

torch.nn.utils.weight_norm(module, name='weight', dim=0)

与上述归一化方法不同的是,这里调用的不是类,而是函数,而且需要包裹一个Module

```
# 5.实现weight_norm并验证API
# 调用 weight_norm
# 因为实现weight_norm需要包裹module, 所以选择最简单的线性层测试
linear = nn.Linear(embedding_dim, 3, bias=False) # 未weight_norm的linear
wn_linear = torch.nn.utils.weight_norm(linear) # 进行weight_norm的linear
wn_linear_output = wn_linear(input_x)
# print(wn_linear_output.shape) # torch.Size([2, 3, 3])
# 手写实现 weight_norm
# 除以模不是指除以整个矩阵的模,而是除以跟每个sample做内积相乘的那个向量的模
# 因为是 X的每一行 与 W转置的每一列相乘 , 也就是W的每一行, 因此是dim = 1 (列顺序即行)
weight_direction = linear.weight / (linear.weight.norm(dim=1,keepdim=True)) #
w = linear.weight, 然后求出w的方向向量(w除以w的模)
weight_magnitude = wn_linear.weight_g # 幅度g
# print(weight_direction.shape) # torch.Size([3, 4])
# print(weight_magnitude.shape) # torch.Size([3, 1])
# 注意要做转置
verify_wn_linear_output = (input_x @ weight_direction.transpose(-1,-2)) \
                        * (weight_magnitude.transpose(-1,-2))
# 验证是否相等
print(wn_linear_output)
print(verify_wn_linear_output)
```